

■ 数学期望与方差

定义 1 设 X 为一离散型随机变量，其分布列为 $P(X = x_i) = p_i, (i = 1, 2, \dots)$ ，若级数 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛，则称这级数为 X 的数学期望，简称期望或均值，记为 $E(X)$ ，即

$$E(X) = \sum_{i=1}^{\infty} x_i p_i$$

否则，称 X 的数学期望不存在。

$$D(X) = \sum_{i=1}^{\infty} [x_i - E(X)]^2 p_i = \sigma^2$$

为 X 的方差，就是 X 的函数 $[X - E(X)]^2$ 的数学期望。

在定义 1 中，要求 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛是必须的，因为 X 的数学期望是一确定的量，不受 $x_i p_i$ 在级数中排列次序的影响，这在数学上就要求级数绝对收敛。 X 的数学期望也称为数 x_i 以概率 p_i 为权的加权平均。

定义 2 设 X 为一连续型随机变量，其密度函数为 $f(x)$ ，若 $\int_{-\infty}^{+\infty} |x| f(x) dx < +\infty$ 时，则称

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \mu$$

为 X 的数学期望，否则称 X 的数学期望不存在。

$$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f(x) dx = \sigma^2$$

计算方差时常用简化公式

$$D(X) = E(X^2) - [E(X)]^2$$

■ 常见分布的数学期望

1. 两点分布

设 $X \sim B(1, p)$ ，即 $P(X = 0) = q, P(X = 1) = p, 0 < p < 1, p + q = 1$ ，则

$$E(X) = 0 \cdot q + 1 \cdot p = p$$

$$D(X) = pq$$

2. 二项分布

设 $X \sim B(k; n, p)$ ，即 $P(X = k) = C_n^k p^k q^{n-k}, k = 0, 1, 2, \dots, n, 0 < p < 1, p + q = 1$ ，则

$$\begin{aligned}
 E(X) &= \sum_{k=0}^n k \cdot P(X=k) = \sum_{k=0}^n k \cdot C_n^k p^k q^{n-k} = \sum_{k=1}^n \frac{np \cdot (n-1)!}{(k-1)! [(n-1)-(k-1)]!} p^k q^{(n-1)-(k-1)} \\
 &= np(p+q)^{n-1} = np
 \end{aligned}$$

$D(X) = npq$ ，证明较复杂，略。

在二项分布中，当 $n \rightarrow \infty, p \rightarrow 0$ 时，概率是服从泊松分布的：

$$\begin{aligned}
 \lim_{n \rightarrow \infty, p \rightarrow 0} C_n^k p^k q^{n-k} &= \lim_{n \rightarrow \infty, p \rightarrow 0} \frac{n(n-1) \dots (n-k+1)}{k!} p^k q^{\frac{np}{p}-k} = \lim_{n \rightarrow \infty, p \rightarrow 0} \frac{n^k}{k!} p^k q^{\frac{np}{p}-k} \\
 &= \lim_{n \rightarrow \infty, p \rightarrow 0} \frac{(np)^k}{k!} \left((1-p)^{\frac{1}{-p}} \right)^{-np} (1-p)^{-k} = \lim_{n \rightarrow \infty, p \rightarrow 0} \frac{\lambda^k}{k!} \left(\left(1 + \frac{-p}{n} \right)^{\frac{n}{-p}} \right)^{-\lambda} \\
 &= \lim_{n \rightarrow \infty, p \rightarrow 0} \frac{\lambda^k}{k!} e^{-\lambda}
 \end{aligned}$$

其中， λ 是泊松分布的期望。

3. 泊松分布

设 $X \sim P(k; \lambda)$ ，即 $P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}, k=0,1,2,\dots, \lambda>0$ ，则

$$E(X) = \sum_{k=0}^n k \cdot P(X=k) = \sum_{k=0}^n k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=1}^n \frac{\lambda^k}{(k-1)!} = \lambda e^{-\lambda} \sum_{k=1}^n \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

其中用到泰勒级数展开式 $e^{\lambda} = \sum_{k=1}^n \frac{\lambda^{k-1}}{(k-1)!}$

这说明，泊松分布的参数 λ 就是服从泊松分布的随机变量的均值。

$$D(X) = \lambda$$

4. 均匀分布

设 $X \sim U[a, b]$ ，即 X 的密度函数为 $f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$ ，则

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{a+b}{2}$$

恰好是 $[a, b]$ 的中点，这与均值意义相符。

$$D(X) = \frac{(b-a)^2}{12}$$

5. 指数分布

设 $X \sim E(\lambda)$ ，即 X 的密度函数为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$ ，则

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_{-\infty}^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \int_{-\infty}^{+\infty} -x de^{-\lambda x} = \frac{1}{\lambda}$$

$$D(X) = \frac{1}{\lambda^2}$$

6. 正态分布

设 $X \sim N(\mu, \sigma^2)$ ，即 X 的密度函数为 $f(x) = \frac{1}{\sigma \cdot \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $-\infty < x < +\infty, \sigma > 0$ ，则

$$E(X) = \frac{1}{\sigma \cdot \sqrt{2\pi}} \int_{-\infty}^{+\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx, \text{ 令 } a = \frac{x-\mu}{\sigma}, \text{ 则}$$

$$E(X) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (\mu + a \cdot \sigma) e^{-\frac{a^2}{2}} da = \frac{\mu}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{a^2}{2}} da + \frac{\sigma}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} a e^{-\frac{a^2}{2}} da = \mu$$

这说明正太分布的参数 μ 是正态随机变量的均值。

$$D(X) = \sigma^2$$

■ 数学期望的性质

定理： (1) $E(c) = c$ ；

(2) $E(cX) = cE(X)$ ；

(3) $E(X+Y) = E(X) + E(Y)$ ；

(4) 设 X, Y 相互独立 $E(XY) = E(X) \cdot E(Y)$ ；

其中 c 为常数，且数学期望都存在。由此定理可推论：

推论 1 $E(c_1X_1 + c_2X_2 + \cdots + c_nX_n + b) = c_1E(X_1) + c_2E(X_2) + \cdots + c_nE(X_n) + b$

其中 c, b 均是常数，特别有 $E(X_1 + X_2 + \cdots + X_n) = E(X_1) + E(X_2) + \cdots + E(X_n)$

推论 2 若 X_1, X_2, \dots, X_n 相互独立，则 $E(X_1 \cdot X_2 \cdot \dots \cdot X_n) = E(X_1) \cdot E(X_2) \cdot \dots \cdot E(X_n)$

■ 方差、协方差的性质

$$D(cX) = c^2D(X)$$

$$D(X+Y) = D(X) + D(Y) + 2Cov(X, Y)$$

$$D(X-Y) = D(X) + D(Y) - 2Cov(X, Y)$$

若 X, Y 是相互独立的随机变量，即 X, Y 不相关，则协方差 $Cov(X, Y) = 0$ ，因为

$$Cov(X, Y) = Cov(Y, X) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X) \cdot E(Y)$$

$$Cov(aX, bY) = abCov(X, Y)$$

$$Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$$

引申：相关系数 ρ_{XY}

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X) \cdot D(Y)}}$$

若 $\rho_{XY} = 0$ ，则称 X Y 不线性相关。充要性满足 $\rho_{XY} = 0 \Leftrightarrow Cov(X, Y) = 0$

■ 总体样本的无偏估计

定义 设统计量 $\hat{\Theta} = \hat{\Theta}(X_1, X_2, \dots, X_n)$ 是总体 Θ 中未知参数的估计量，若 $E(\hat{\Theta}) = \Theta$ ，则称 $\hat{\Theta}$ 为 Θ 的无偏估计量；否则称为有偏估计量。

上面这个定义的意思就是说如果拿到了一堆样本观测值，然后想通过这一堆观测值去估计某个统计量 Θ （一般就是想估计总体的期望或方差），如果选择的方法所估计出来的统计量 $\hat{\Theta}$ 的期望值与总体样本的统计量 Θ 相等，那么我们称这种方法下的估计量是无偏估计量，否则为有偏估计量。

有偏无偏是针对选择估计的方法所说的，它并不是针对具体某一次估计出来的估计量结果。如果方法不对，即使恰好在某一次计算出来一个值和总体样本统计量值相同，也并不代表所选的这个方法是无偏的。因为单次 $\hat{\Theta}$ 值是和选取的样本相关的，每次样本（更加严格的意义是某次样本快照）的值变化了，那么每次 $\hat{\Theta}$ 的值就有可能跟着变化，需对多个 $\hat{\Theta}$ 求期望值来判断 $\hat{\Theta}$ 的可信程度，如果一直重复这个试验，然后它的期望值与总体样本的统计量 Θ 一样，那么称按照这种方法估计出来的统计量是无偏的。

只有在无法通过整体直接“统计”获得你想要的“量”时，只能通过“部分样本”来做“整体样本”“量”的估计时，谈估计方法的“有偏”还是“无偏”才是有意义的。

重要假设 随机选取的样本 X_i 与总体样本 X 同分布，就是说他们的统计特性是完全一样的，即他们的期望值一样，方差值也一样，即

$$E(X_i) = E(X) = \mu$$

$$D(X_i) = D(X) = \sigma^2$$

定理 1 样本均值 \bar{X} 是总体样本均值 μ 的无偏估计。

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{\sigma^2}{n}$$

定理 2 样本方差 s^2 是总体样本方差 σ^2 的无偏估计。即

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$
$$E(s^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \sigma^2$$

证明网查。之所以不是 $\frac{1}{n}$ ，是因为 $D(\bar{X}) \neq 0$ 。或者如果已知总体均值 μ ，则

$$s^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

但实际上，总体均值 μ 都是未知的。